

Signaux précurseurs performatifs

Un premier modèle formel de la réflexivité dans la détection de bascules collectives

Septembre 2026

Ce document pose et résout un premier modèle mathématique reliant deux champs établis séparément — les signaux précurseurs de bascule (ralentissement critique) et la prédiction performative — sans qu'aucun travail trouvé ne les combine formellement à ce jour (vérifié par recherche approfondie puis par recoupement direct des bibliographies des synthèses les plus récentes de chaque champ). Ce n'est pas présenté comme une théorie complète de la réflexivité, mais comme un premier modèle jouet, dérivé et vérifié numériquement, destiné à servir de point de départ à une collaboration ouverte plutôt que comme un résultat définitif.

Contents

1	Motivation et positionnement honnête	1
2	État de l'art et positionnement précis	2
3	Le modèle	2
3.1	Rappel du cadre sans rétroaction	2
3.2	Introduire la performativité	3
3.3	L'équation de point fixe	3
4	Analyse du point fixe	3
5	Validation par simulation stochastique complète	4
5.1	Sensibilité aux paramètres de la fonction d'alerte	5
5.2	Extension au modèle de Kuramoto (H4)	5
6	Limites assumées de ce premier modèle	6
7	Prochaines étapes possibles	7

1 Motivation et positionnement honnête

Les indicateurs de ralentissement critique (variance, autocorrélation) supposent un paramètre de contrôle $\lambda(t)$ purement exogène — le système physique ou écologique observé ne « lit » jamais l'indicateur calculé sur lui-même. Cette hypothèse est raisonnable pour un lac ou un plasma. Elle est fausse par construction pour un système social observé par un outil comme Hélios : si l'alerte est publiée, les acteurs peuvent y réagir, et cette réaction change la trajectoire même que l'indicateur cherchait à décrire.

Remarque

Ce problème porte un nom en apprentissage automatique — la *prédiction performative* (Perdomo, Zrnic, Mendler-Dünnér & Hardt, 2020) — et un nom informel en économie/-finance — la *réflexivité* (Soros) ou la *critique de Lucas*. Mais aucun des deux cadres n’a été formalisé dans le langage mathématique précis des signaux précurseurs (variance, autocorrélation, ralentissement critique). C’est exactly le vide que ce document tente de combler, modestement.

2 État de l’art et positionnement précis

Une revue approfondie (recherche multi-sources, puis vérification directe des bibliographies des deux synthèses les plus récentes de chaque champ — Hardt & Mendler-Dünnér, 2025, *Statistical Science* ; « Dissecting Performative Prediction », 2026) ne trouve aucun travail combinant formellement les deux cadres. Les travaux les plus proches, chacun d’un seul côté du pont :

- **Diekert, Heyen, Nesje & Shayegh (2025)**, *J. R. Soc. Interface* — le lien formel le plus proche : un système d’alerte précoce change les décisions d’un planificateur, et peut produire un comportement *plus* risqué en l’absence d’alerte. Un seul décideur rationnel, pas de population réactive, pas de statistique de ralentissement critique.
- **Bauch, Sigdel, Pharaon & Anand (2016)**, *PNAS* — la rétroaction humaine peut « atténuer le signal précurseur », rendant une bascule à venir plus difficile à détecter, dans un modèle couplé forêt-opinion.
- **Diks, Hommes & Wang (2019)**, *Empirical Economics* — notent, en une phrase, qu’une crise prédite « peut causer une réaction de panique des agents et ainsi déclencher une crise à venir encore plus tôt », sans le formaliser.
- **Sornette (2003)**, *Physics Reports* — liste, de façon informelle, les scénarios où une prédiction publique de krach s’auto-réalise ou s’auto-invalide.
- **Drehmann & Juselius (2014)**, *BIS/Int. J. Forecasting* — notent qu’un indicateur d’alerte utilisé en politique publique « deviendra sujet à la critique de Lucas usuelle », et que la perte de pouvoir prédictif serait « plutôt un signe de son succès ».

Limite assumée

Cette revue s’appuie sur une recherche documentaire, pas sur une base de données de citations exhaustive. L’absence de résultat n’est pas une preuve d’absence définitive.

3 Le modèle

3.1 Rappel du cadre sans rétroaction

Le modèle de ralentissement critique déjà établi (processus d’Ornstein-Uhlenbeck près d’une bifurcation) s’écrit :

$$dy = \lambda(t) y dt + \sigma dW, \quad \lambda(t) \rightarrow 0^-$$

avec la variance stationnaire $\text{Var}(y) = \sigma^2/(2|\lambda|)$ et l’autocorrélation $\text{AC1} \rightarrow 1$ quand $\lambda \rightarrow 0^-$ — le signal précurseur classique. Ce résultat suppose $\lambda(t)$ exogène.

3.2 Introduire la performativité

Postulat

Un détecteur observe la variance glissante V_t et publie une alerte $a_t = A(V_t) \in [0, 1]$, une fonction sigmoïde croissante de V_t . Cette alerte modifie en retour le paramètre de stabilité effectif du système :

$$\lambda_{\text{eff}}(t) = \lambda(t) + \kappa \cdot A(V_t), \quad A(V) = \frac{1}{1 + e^{-k(V-V_c)}}$$

où κ est le *coefficient de rétroaction performative* ($\kappa < 0$: réponse stabilisatrice/auto-invalidante ; $\kappa > 0$: réponse déstabilisatrice/auto-réalisatrice), k la sensibilité de l'alerte, V_c le seuil de déclenchement.

Remarque

κ joue exactement le rôle de la sensibilité ε dans le cadre de Perdomo et al. (le décalage de distribution induit par le paramètre du modèle), transposé ici au paramètre de stabilité d'un processus stochastique plutôt qu'à une distribution de caractéristiques.

3.3 L'équation de point fixe

En régime quasi-stationnaire ($V_t \approx \sigma^2/(2|\lambda_{\text{eff}}|)$, séparation d'échelles de temps admise), on obtient une équation implicite auto-cohérente pour λ_{eff} :

$$\lambda_{\text{eff}} = \lambda(t) + \kappa \cdot A\left(\frac{\sigma^2}{2|\lambda_{\text{eff}}|}\right)$$

Remarque

Structure identique à l'équation d'auto-cohérence de Kuramoto déjà résolue pour H4 (§5.8 du cahier des charges Hélios) — le champ moyen r y jouait le rôle que joue ici λ_{eff} .

4 Analyse du point fixe

Résultat — Deux régimes qualitativement distincts

Selon le signe de κ , l'équation de point fixe se comporte de deux façons radicalement différentes lorsque $\lambda(t) \rightarrow 0^-$:

- $\kappa = 0$: $\lambda_{\text{eff}} = \lambda(t)$, on retrouve le cas classique (vérification de cohérence).
- $\kappa < 0$ (auto-invalidant) : λ_{eff} reste **borné loin de zéro** même quand $\lambda(t) \rightarrow 0^-$ — la variance ne diverge plus, elle plafonne.
- $\kappa > 0$ (auto-réalisateur) : il existe un $\lambda_c(\kappa) < 0$ tel que **le point fixe cesse d'exister** pour $\lambda(t) > \lambda_c(\kappa)$ — la bascule (au sens de cette équation) survient avant que le système « nu » n'y soit arrivé.

Démonstration / dérivation. Résolution numérique par bisection de $f(\lambda_{\text{eff}}) = \lambda_{\text{eff}} - \lambda(t) - \kappa A(\sigma^2/2|\lambda_{\text{eff}}|) = 0$, pour $\sigma = 1$, $k = 10$, $V_c = 2$:

Cas $\kappa < 0$ — extrait ($\kappa = -0,1$) :

$\lambda(t)$	λ_{eff}	Var
-1,000	-1,000	0,50
-0,100	-0,199	2,51
-0,010	-0,110	4,55
-0,001	-0,101	4,95

Même quand $\lambda(t)$ s'approche de 0 à 10^{-3} près, λ_{eff} reste proche de -0,1 — un **plancher de stabilité performatif**. La divergence classique de la variance n'apparaît jamais.

Cas $\kappa > 0$ — extrait ($\kappa = 0,05$) :

$\lambda(t)$	Solution
-0,500	$\lambda_{\text{eff}} = -0,500$
-0,100	$\lambda_{\text{eff}} = -0,050$
-0,050	pas de solution
-0,020	pas de solution

Le point fixe disparaît entre $\lambda = -0,1$ et $\lambda = -0,05$ — bien avant que le système nu n'atteigne $\lambda = 0$. Plus κ augmente, plus $\lambda_c(\kappa)$ s'éloigne de 0 (bascule anticipée plus tôt). ■

5 Validation par simulation stochastique complète

L'analyse précédente repose sur l'approximation quasi-stationnaire. Pour vérifier qu'elle tient dans un vrai système bruité, avec une variance glissante calculée en temps réel sur une fenêtre finie (pas la formule fermée), le système complet a été simulé par Euler-Maruyama :

$$y_{n+1} = y_n + dt (\lambda(t_n) + \kappa A(V_n)) y_n + \sigma \sqrt{dt} \xi_n$$

Remarque

[Erreur trouvée et corrigée en cours de route] Un premier essai avec une fenêtre glissante de 0,5 unité de temps n'a montré **aucune différence entre les valeurs de κ** — le temps de relaxation du système près de la bifurcation ($\sim 1/|\lambda|$) dépasse largement la taille de la fenêtre, donc la variance mesurée restait toujours proche de 0 et l'alerte ne se déclenchait jamais, quel que soit κ . Corrigé en portant la fenêtre à 20 unités de temps (recalibrée en vérifiant que la variance mesurée suit bien la prédiction théorique en régime $\kappa = 0$ avant de comparer les régimes entre eux) — exactement le type d'erreur que ce projet a appris à détecter systématiquement plutôt qu'à laisser passer.

Résultat (500 réalisations indépendantes par valeur de κ , graine de base explicite = 42 — reproductible, pas de dérivation informelle par fonction de hachage —, $\lambda_0 = -1$, taux de dérive 0,002, seuil de bascule $|y| > 8$) :

Régime	Bascules	Taux	Temps moyen (écart-type)
$\kappa = 0$ (classique)	317/500	63,4%	504,2 (15,7)
$\kappa = -0,05$	162/500	32,4%	508,5 (14,3)
$\kappa = -0,10$	51/500	10,2%	510,9 (13,6)
$\kappa = -0,20$	15/500	3,0%	509,6 (12,6)
$\kappa = +0,02$	373/500	74,6%	499,3 (16,9)
$\kappa = +0,05$	442/500	88,4%	493,0 (19,1)
$\kappa = +0,08$	480/500	96,0%	483,9 (20,8)

Remarque

[Vérification de l'absence de bistabilité cachée] L'analyse du §4 repose sur une résolution par bisection, qui suppose implicitement une seule racine dans l'intervalle testé. Pour écarter l'hypothèse d'un pli à deux solutions (bistabilité/hystérésis) que la bisection aurait pu manquer, la fonction résiduelle a été scannée finement (jusqu'à 20 000 points, avec un zoom à 21 points entre $\lambda = -0,06$ et $-0,05$) autour de la zone de transition pour $\kappa = 0,05$. Résultat : exactement une racine jusqu'à $\lambda \approx -0,0505$, puis zéro — un vrai pli net (tangence), aucune fenêtre à deux solutions cachée. La caractérisation du §4 est donc confirmée, pas seulement supposée.

5.1 Sensibilité aux paramètres de la fonction d'alerte

Le résultat qualitatif (monotonie du taux de bascule en fonction de κ) a été revérifié à **1000 réalisations**, pour 5 combinaisons de la pente k et du seuil V_c de la fonction d'alerte ($k \in \{5, 10, 20\}$, $V_c \in \{1,5; 2; 2,5\}$) : la monotonie tient dans les 5 cas.

Remarque

[Nuance nécessaire — monotonie au sens large, pas stricte partout] Un test de sensibilité complémentaire au **seuil de bascule lui-même** ($|y| > y_{\text{thresh}}$, jusqu'ici jamais testé) montre que la monotonie stricte ne tient qu'à $y_{\text{thresh}} = 8$. À $y_{\text{thresh}} = 12$ (seuil élevé), $\kappa = -0,1$ et $\kappa = -0,2$ donnent tous deux 0,0% — un effet de plancher (les deux régimes empêchent totalement la bascule dans l'horizon simulé), pas une inversion de tendance, mais qui rompt la stricte monotonie affichée sans nuance dans une première version de ce document. Le résultat correct à retenir : **monotonie au sens large (jamais d'inversion), avec saturation possible aux seuils extrêmes** — pas une monotonie stricte inconditionnelle.

y_{thresh}	$\kappa=0$	$\kappa=-0,1$	$\kappa=-0,2$	$\kappa=+0,05$	$\kappa=+0,08$
5	97,8%	83,4%	72,8%	99,6%	99,6%
8	63,4%	10,2%	3,0%	88,4%	96,0%
12	35,8%	0,0%	0,0%	82,4%	93,8%

5.2 Extension au modèle de Kuramoto (H4)

Pour vérifier que le mécanisme n'est pas propre au modèle nœud-col, la même construction (alerte $A(r_t)$ sur le paramètre d'ordre r au lieu de la variance, $K_{\text{eff}}(t) = K_0(t) + \kappa A(r_t)$) a été appliquée au modèle de synchronisation déjà utilisé pour H4 (§5.8) :

Régime	Basculés (sur 500)	Temps moyen
$\kappa = 0$ (classique)	500/500	141,7
$\kappa = -0,5$	500/500	273,0
$\kappa = -1,0$	495/500	402,1
$\kappa = -2,0$	0/500	—
$\kappa = +0,5$	500/500	50,5
$\kappa = +1,0$	500/500	22,5
$\kappa = +2,0$	500/500	12,2

Remarque

[Asymétrie trouvée lors d'une relecture critique — à ne pas passer sous silence] Contrairement à ce qu'une première lecture du tableau ci-dessus suggère, les deux régimes ne sont **pas confirmés symétriquement** sur ce modèle. Un test de sensibilité au seuil de bascule $r_{\text{tip}} \in \{0,6; 0,7; 0,8\}$ (200 réalisations, régime auto-réalisateur) montre que le *taux* de bascule sature à 100% dès $\kappa = +1$, quel que soit r_{tip} testé — seul le *délai moyen* continue à discriminer entre les valeurs de κ côté auto-réalisateur. Le mécanisme auto-invalidant, lui, discrimine bien à la fois sur le taux et sur le délai (voir $\kappa = -2$, effondrement net du taux). **À retenir** : sur Kuramoto, c'est la variable temporelle qui porte l'essentiel du signal auto-réalisateur, pas le taux de bascule — une asymétrie réelle entre les deux modèles testés, qui n'existe pas sur le nœud-col (où taux *et* délai discriminent des deux côtés).

Même signature qualitative sur une dynamique de nature complètement différente (synchronisation collective plutôt qu'une bifurcation simple) : plancher de stabilité net côté auto-invalidant, accélération monotone côté auto-réalisateur. Le mécanisme ne dépend donc pas du choix particulier du modèle sous-jacent.

Limite assumée

« 0/30 bascule » à $\kappa = -0,2$ signifie *dans l'horizon temporel simulé* (jusqu'à $\lambda(t) = 0,05$) — pas que la bascule est impossible dans l'absolu. Un temps de simulation plus long ou un taux de dérive de $\lambda(t)$ plus rapide pourrait finir par forcer la bascule même à κ très négatif.

6 Limites assumées de ce premier modèle**Limite assumée**

- Un seul mécanisme de rétroaction est modélisé (réponse linéaire du paramètre de stabilité à une alerte sigmoïde). Les mécanismes de *masquage stratégique* (loi de Goodhart — des acteurs qui suppriment délibérément les fluctuations mesurées) et d'*aléa moral* (comportement plus risqué en l'*absence* d'alerte, Diekert et al.) ne sont pas modélisés ici.
- Le détecteur ne se recalibre pas — pas de boucle de ré-entraînement au sens de la « stabilité performative » de Perdomo et al. (convergence d'une politique de décision sous minimisation de risque répétée). Ce modèle teste un κ fixé, pas la convergence d'un processus d'apprentissage.
- Validé sur deux modèles déjà internes à Hélios (nœud-col, Kuramoto), à 500-1000 réalisations, avec vérification de sensibilité aux paramètres de la fonction d'alerte — mais toujours aucun test sur données réelles, aucune relecture par un chercheur extérieur au domaine, et une vérification bibliographique par recoupement de synthèses plutôt que par une base de citations exhaustive (Semantic Scholar / Google Scholar complet).
- C'est un premier modèle jouet, pas une théorie de la réflexivité sociale. Présenté comme point de départ pour une collaboration plus large, pas comme un résultat clos.

7 Prochaines étapes possibles

1. Formaliser le mécanisme de masquage stratégique (Goodhart) comme second modèle, complémentaire à celui-ci.
2. Étudier la convergence d'un détecteur qui recalibre son seuil V_c à partir des données déjà influencées par ses propres alertes passées — la vraie notion de « stabilité performative » au sens de Perdomo et al., pas seulement un κ fixe.
3. Tester sur un vrai jeu de données où la réflexivité est plausible et où des signaux de type ralentissement critique ont déjà été cherchés — les marchés financiers (Diks, Hommes & Wang, 2019 ; Guttal et al., 2016) sont le candidat le plus direct.
4. Décision ouverte : héberger ce travail comme extension d'Hélios, ou comme projet et interface séparés, étant donné sa nature plus spéculative et son statut de première tentative sur un vide de recherche identifié plutôt que d'application d'une méthode établie.

Références

- Perdomo, J., Zrnic, T., Mendler-Dünner, C., & Hardt, M. (2020). "Performative Prediction." *ICML 2020*, PMLR 119.
- Hardt, M., & Mendler-Dünner, C. (2025). "Performative Prediction: Past and Future." *Statistical Science*, 40(3), 417–436.
- Diekert, F., Heyen, D., Nesje, F., & Shayegh, S. (2025). "Do early warning signals of tipping points lead to better decisions?" *Journal of the Royal Society Interface*, 22(225), 20240864.
- Bauch, C. T., Sigdel, R., Pharaon, J., & Anand, M. (2016). "Early warning signals of regime shifts in coupled human–environment systems." *PNAS*, 113(51), 14560–14567.
- Diks, C., Hommes, C., & Wang, J. (2019). "Critical slowing down as an early warning signal for financial crises?" *Empirical Economics*, 57(4), 1201–1228.
- Sornette, D. (2003). "Critical market crashes." *Physics Reports*, 378, 1–98.
- Drehmann, M., & Juselius, M. (2014). "Evaluating early warning indicators of banking crises: Satisfying policy requirements." *International Journal of Forecasting*, 30(3).
- Scheffer, M. et al. (2009). "Early-warning signals for critical transitions." *Nature*, 461, 53–59.
- Guttal, V., Raghavendra, S., Goel, N., & Hoarau, Q. (2016). "Lack of Critical Slowing Down Suggests that Financial Meltdowns Are Not Critical Transitions, yet Rising Variability Could Signal Systemic Risk." *PLOS ONE*, 11(1), e0144198.